Машинное обучение

НИЯУ МИФИ, Кафедра финансового мониторинга.

Лабораторный практикум.

В.Ю. Радыгин, Д.Ю. Куприянов, Манаенкова Т.А.

Семестр 1. Лабораторная работа 2

Лабораторная работа 2 рассчитана на два занятия и работу дома. Её целью является изучение основ анализа данных, заданных в количественной и номинальной шкалах.

Вариант 1

1) **Количественные данные**

Могут быть полезны следующие ссылки:
https://cbr.ru/currency_base/dynamics/
https://bhom.ru/commodities
https://www.finam.ru/profile/tovary/brent/export

1. Соберите в интернете набор данных о курсах американского доллара, канадского доллара и евро не менее, чем за последние 50 месяцев (как минимум одно наблюдение на месяц). Курсы валют должны быть приведены к одинаковым единицам измерения. Например, количество рублей за единицу валюты или количество фунтов стерлингов за единицу валюты и т.д.
2. Загрузите собранную информацию в набор Pandas DataFrame, назвав переменные USD, CAD, EUR соответственно.
3. Выполните графическое исследование для каждой из переменных на предмет совпадения её распределения с нормальным при помощи графиков P-P и Q-Q. При необходимости выполните нормализацию или стандартизацию данных.
4. Проверьте приблизительное равенство моды, медианы и среднего арифметического значения исследуемого набора данных. Постройте их на гистограмме исследуемого набора данных.
5. Выполните аналитическое исследование для каждой из переменных на предмет совпадения её распределения с нормальным. Обоснованно выберите один из методов: Шапиро-Уилка, Андерсона-Дарлинга или Колмогорова-Смирнова.
6. Удалите наиболее заметные выбросы и повторите исследование.
7. Для каждой из пар переменных выполните графическое исследование данной пары на предмет взаимной корреляции.
8. Для каждой из пар переменных выполните оценку с помощью методов Пирсона, Спирмена, Кендалла. Объясните, какой из методов было лучше использовать в вашем случае. Дайте интерпретацию полученных результатов.

2) **Номинальные данные**

Зарегистрируйтесь на сайте https://www.kaggle.com/datasets и загрузите с него набор статистических данных, посвящённый опросам людей https://www.kaggle.com/freecodecamp/2016-new-coder-survey-/version/1

1. На основе загруженного CSV-файла создайте Pandas DataFrame, подобрав правильные типы данных столбцов.
2. Создайте новый Pandas DataFrame, выбрав только переменные EmploymentField, EmploymentStatus, Gender, JobPref, JobWherePref, MaritalStatus, Income.
3. Удалите все наблюдения, содержащие либо значения поля пол (Gender), отличные от male или female, либо значения NA (нет ответа) в каких-либо из полей.
4. Исследуйте связи между парами переменных (используйте только наблюдения, где эти поля заполнены):
   a) Gender, JobPref;
   b) Gender, JobWherePref;
   c) JobWherePref, MaritalStatus;
   d) EmploymentField, JobWherePref;
   e) EmploymentStatus, JobWherePref.

Выполняя исследование, не используйте процедуру ANOVA. Для каждой пары постройте таблицу сопряжённости, таблицу ожидаемых значений. Обоснованно выберите один из методов: хи-квадрат Пирсона, хи-квадрат Пирсона с поправкой Йейтса, точный критерий

Фишера (обычный или на основе приближения Монте-Карло), точный критерий Фримана-Холтона (обычный или на основе приближения Монте-Карло).
Для каждой пары интерпретируйте результаты.

Вариант 2

1) Количественные данные

Могут быть полезны следующие ссылки:
https://cbr.ru/currency_base/dynamics/
https://bhom.ru/commodities
https://www.finam.ru/profile/tovary/brent/export

1. Соберите в интернете набор данных о цене барреля нефти BRENT и курсах российского рубля и нигерийской найры не менее, чем за последние 50 месяцев (как минимум одно наблюдение на месяц). Курсы валют и цена барреля должны быть приведены к одинаковым единицам измерения. Например, количество долларов за единицу валюты или барель.
2. Загрузите собранную информацию в набор Pandas DataFrame, назвав переменные BAR, RUB, NGN соответственно.
3. Выполните графическое исследование для каждой из переменных на предмет совпадения её распределения с нормальным при помощи графиков P-P и Q-Q. При необходимости выполните нормализацию или стандартизацию данных.
4. Проверьте приблизительное равенство моды, медианы и среднего арифметического значения исследуемого набора данных. Постройте их на гистограмме исследуемого набора данных.
5. Выполните аналитическое исследование для каждой из переменных на предмет совпадения её распределения с нормальным. Обоснованно выберите один из методов: Шапиро-Уилка, Андерсона-Дарлинга или Колмогорова-Смирнова.
6. Удалите наиболее заметные выбросы и повторите исследование.
7. Для каждой из пар переменных выполните графическое исследование данной пары на предмет взаимной корреляции.
8. Для каждой из пар переменных выполните оценку с помощью методов Пирсона, Спирмена, Кендалла. Объясните, какой из методов было лучше использовать в вашем случае. Дайте интерпретацию полученных результатов.

2) Номинальные данные

Зарегистрируйтесь на сайте https://www.kaggle.com/datasets и загрузите с него набор статистических данных, посвящённый опросам людей https://www.kaggle.com/freecodecamp/2016-new-coder-survey-/version/1

1. На основе загруженного CSV-файла создайте Pandas DataFrame, подобрав правильные типы данных столбцов.
2. Создайте новый Pandas DataFrame, выбрав только переменные EmploymentField, EmploymentStatus, Gender, LanguageAtHome, JobWherePref, SchoolDegree, Income.
3. Удалите все наблюдения, содержащие либо значения поля пол (Gender), отличные от male или female, либо значения NA (нет ответа) в каких-либо из полей.
4. Исследуйте связи между парами переменных (используйте только наблюдения, где эти поля заполнены):
   a) Gender, SchoolDegree;

b) Gender, JobWherePref;
c) JobWherePref, LanguageAtHome;
d) EmploymentField, LanguageAtHome;
e) EmploymentStatus, LanguageAtHome.

Выполняя исследование, не используйте процедуру ANOVA. Для каждой пары постройте таблицу сопряжённости, таблицу ожидаемых значений. Обоснованно выберите один из методов: хи-квадрат Пирсона, хи-квадрат Пирсона с поправкой Йейтса, точный критерий Фишера (обычный или на основе приближения Монте-Карло), точный критерий Фримана-Холтона (обычный или на основе приближения Монте-Карло).

Для каждой пары интерпретируйте результаты.

Вариант 3

1) Количественные данные

Могут быть полезны следующие ссылки:
https://cbr.ru/currency_base/dynamics/
https://bhom.ru/commodities
https://www.finam.ru/profile/tovary/brent/export

1. Соберите в интернете набор данных о ставках рефинансирования и курсах национальных валют России и Казахстана не менее, чем за последние 50 месяцев (как минимум одно наблюдение на месяц). Курсы валют должны быть приведены к одинаковым единицам измерения. Например, количество долларов за единицу валюты.
2. Загрузите собранную информацию в набор Pandas DataFrame.
3. Выполните графическое исследование для каждой из переменных на предмет совпадения её распределения с нормальным при помощи графиков P-P и Q-Q. При необходимости выполните нормализацию или стандартизацию данных.
4. Проверьте приблизительное равенство моды, медианы и среднего арифметического значения исследуемого набора данных. Постройте их на гистограмме исследуемого набора данных.
5. Выполните аналитическое исследование для каждой из переменных на предмет совпадения её распределения с нормальным. Обоснованно выберите один из методов: Шапиро-Уилка, Андерсона-Дарлинга или Колмоговора-Смирнова.
6. Удалите наиболее заметные выбросы и повторите исследование.
7. Для каждой из пар переменных выполните графическое исследование данной пары на предмет взаимной корреляции.
8. Для каждой из пар переменных выполните оценку с помощью методов Пирсона, Спирмена, Кендалла. Объясните, какой из методов было лучше использовать в вашем случае. Дайте интерпретацию полученных результатов.

2) Номинальные данные

Зарегистрируйтесь на сайте https://www.kaggle.com/datasets и загрузите с него набор статистических данных, посвящённый опросам людей https://www.kaggle.com/freecodecamp/2016-new-coder-survey-/version/1

1. На основе загруженного CSV-файла создайте Pandas DataFrame, подобрав правильные типы данных столбцов.
2. Создайте новый Pandas DataFrame, выбрав только переменные EmploymentField, EmploymentStatus, Gender, LanguageAtHome, JobWherePref, SchoolDegree, Income.
3. Удалите все наблюдения, содержащие либо значения поля пол (Gender), отличные от male или female, либо значения NA (нет ответа) в каких-либо из полей.
4. Исследуйте связи между парами переменных (используйте только наблюдения, где эти поля заполнены):
   a) Gender, SchoolDegree;
   b) Gender, JobWherePref;
   c) JobWherePref, LanguageAtHome;
   d) EmploymentField, LanguageAtHome;
   e) EmploymentStatus, LanguageAtHome.

   Выполняя исследование, не используйте процедуру ANOVA. Для каждой пары постройте таблицу сопряжённости, таблицу ожидаемых значений. Обоснованно выберите один из методов: хи-квадрат Пирсона, хи-квадрат Пирсона с поправкой Йейтса, точный критерий Фишера (обычный или на основе приближения Монте-Карло), точный критерий Фримана-Холтона (обычный или на основе приближения Монте-Карло).

   Для каждой пары интерпретируйте результаты.